

DAF: مکانیزم توجه پویا برای شبکه‌های کانولوشنی

Dynamic Attention Fusion for Convolutional Neural Networks

درس: رایانش عصبی و یادگیری عمیق

دانشجو: مهدی دلنوازی

404198476

چکیده

شبکه‌های عصبی کانولوشنی (CNN) به عنوان یکی از موفق‌ترین روش‌های یادگیری عمیق، کاربرد گسترده‌ای در مسائل بینایی ماشین و طبقه‌بندی تصاویر پیدا کرده‌اند. با وجود عملکرد مناسب این شبکه‌ها، تمامی نقشه‌های ویژگی استخراج شده در فرآیند یادگیری به صورت یکسان مورد استفاده قرار می‌گیرند و اهمیت نسبی ویژگی‌های مختلف برای هر تصویر به طور مستقیم در نظر گرفته نمی‌شود. به منظور رفع این محدودیت، مکانیزم‌های توجه مختلفی نظیر SE-Net و CBAM ارائه شده‌اند که به ترتیب از توجه کانالی و ترکیب توجه کانالی و مکانی بهره می‌برند.

در این پژوهش، یک مکانیزم توجه جدید با عنوان ادغام پویای توجه (Dynamic Attention Fusion - DAF) پیشنهاد می‌شود. در روش پیشنهادی، با استفاده از میزان پراکندگی اطلاعات موجود در نقشه‌های ویژگی، سهم توجه کانالی و توجه مکانی به صورت پویا و متناسب با محتوای هر تصویر تعیین می‌شود. بدین ترتیب، شبکه قادر خواهد بود بر مهم‌ترین ویژگی‌ها و نواحی تصویر تمرکز بیشتری داشته باشد. به منظور ارزیابی عملکرد روش پیشنهادی، معماری DAF بر پایه شبکه ResNet18 پیاده‌سازی و بر روی مجموعه داده CIFAR-10 مورد آزمایش قرار گرفته است. همچنین عملکرد آن با مدل پایه ResNet18 و مکانیزم‌های توجه متداول نظیر SE-Net و CBAM مقایسه خواهد شد. انتظار می‌رود نتایج این پژوهش نشان دهد که استفاده از مکانیزم ادغام پویای توجه می‌تواند موجب بهبود دقت طبقه‌بندی و افزایش توانایی شبکه در تمرکز بر ویژگی‌های مؤثر تصویر شود.

فصل اول: مقدمه

در سال‌های اخیر، پیشرفت‌های چشمگیر در حوزه یادگیری عمیق موجب تحول گسترده‌ای در بسیاری از زمینه‌های هوش مصنوعی شده است. یکی از مهم‌ترین شاخه‌های این پیشرفت، بینایی ماشین است که هدف آن توانمندسازی سیستم‌های کامپیوتری برای درک و تفسیر محتوای تصاویر و ویدئوها می‌باشد. کاربردهای بینایی ماشین امروزه در حوزه‌های متعددی از جمله تشخیص چهره، خودروهای خودران، تصویربرداری پزشکی، سیستم‌های نظارتی، کشاورزی هوشمند و رباتیک مشاهده می‌شود.

در میان مدل‌های یادگیری عمیق، شبکه‌های عصبی کانولوشنی (CNN) به عنوان یکی از موفق‌ترین معماری‌ها برای پردازش تصاویر شناخته می‌شوند. این شبکه‌ها با استفاده از فیلترهای کانولوشنی قادر هستند ویژگی‌های مختلف تصویر را در سطوح مختلف استخراج نمایند. لایه‌های ابتدایی معمولاً ویژگی‌های ساده‌ای مانند لبه‌ها و بافت‌ها را استخراج می‌کنند، در حالی که لایه‌های عمیق‌تر قادر به یادگیری الگوهای پیچیده‌تر و مفاهیم سطح بالا هستند.

موفقیت CNN ها موجب شده است که این معماری به ستون اصلی بسیاری از سامانه‌های بینایی ماشین تبدیل شود. با این وجود، هنوز محدودیت‌هایی در نحوه پردازش ویژگی‌ها توسط این شبکه‌ها وجود دارد که می‌تواند عملکرد آن‌ها را در برخی کاربردها تحت تأثیر قرار دهد.

1-1 بیان مسئله

اگرچه CNN ها توانایی بالایی در استخراج ویژگی‌های تصویری دارند، اما تمامی ویژگی‌های استخراج‌شده را با اهمیت تقریباً یکسان پردازش می‌کنند. به عبارت دیگر، شبکه به طور ذاتی قادر نیست تشخیص دهد کدام ویژگی‌ها برای تصمیم‌گیری نهایی اهمیت بیشتری دارند و کدام ویژگی‌ها کم‌اهمیت یا حتی نویز محسوب می‌شوند.

به عنوان مثال، در مسئله تشخیص گربه، ویژگی‌هایی نظیر شکل گوش‌ها، چشم‌ها و بافت خز نقش مهمی در طبقه‌بندی تصویر دارند. در مقابل، بخش‌هایی از پس‌زمینه مانند آسمان، دیوار یا اشیای نامرتب ممکن است تأثیر چندانی در تصمیم‌گیری نهایی نداشته باشند. با این حال، در CNN های معمولی تمامی این اطلاعات در فرآیند استخراج ویژگی مورد استفاده قرار می‌گیرند.

این موضوع باعث می‌شود بخشی از ظرفیت مدل صرف پردازش اطلاعات کم‌اهمیت شود. در نتیجه پژوهشگران به دنبال توسعه روش‌هایی بوده‌اند که بتوانند توجه شبکه را به مهم‌ترین ویژگی‌های تصویر هدایت کنند.

1-2 مکانیزم‌های توجه در شبکه‌های عصبی

مکانیزم توجه (Attention Mechanism) یکی از مهم‌ترین مفاهیم مطرح‌شده در سال‌های اخیر در حوزه یادگیری عمیق است. ایده اصلی توجه آن است که مدل بتواند بخش‌های مهم داده را شناسایی کرده و اهمیت بیشتری به آن‌ها اختصاص دهد.

در حوزه CNN، مکانیزم‌های توجه معمولاً در دو دسته اصلی قرار می‌گیرند:

توجه کانالی (Channel Attention)

در این نوع توجه، شبکه یاد می‌گیرد کدام کانال‌های ویژگی مهم‌تر هستند. هر کانال معمولاً نمایانگر یک ویژگی خاص از تصویر است و توجه کانالی تلاش می‌کند اهمیت هر کانال را تعیین کند.

توجه مکانی (Spatial Attention)

در این روش، اهمیت نواحی مختلف تصویر مشخص می‌شود. هدف این است که شبکه روی مناطق مهم تصویر تمرکز بیشتری داشته باشد و نواحی کم‌اهمیت را نادیده بگیرد.

1-3 محدودیت روش‌های موجود

در سال‌های اخیر مکانیزم‌های متعددی برای اعمال توجه در شبکه‌های کانولوشنی معرفی شده‌اند. از میان آن‌ها، SE-Net و CBAM از شناخته‌شده‌ترین روش‌ها هستند.

SE-Net با استفاده از مکانیزم توجه کانالی، اهمیت نسبی هر کانال را تعیین می‌کند. اگرچه این روش موجب بهبود عملکرد بسیاری از مدل‌ها شده است، اما اطلاعات مکانی تصویر را در نظر نمی‌گیرد.

CBAM با ترکیب توجه کانالی و مکانی تلاش می‌کند این محدودیت را برطرف نماید. با وجود این، در CBAM نحوه استفاده از این دو نوع توجه برای تمامی تصاویر یکسان است و مکانیزم تصمیم‌گیری پویایی برای تعیین سهم هر نوع توجه وجود ندارد.

این موضوع می‌تواند یک محدودیت بالقوه باشد، زیرا تصاویر مختلف دارای ساختارها و پیچیدگی‌های متفاوتی هستند و ممکن است نیازمند راهبردهای متفاوتی برای اعمال توجه باشند.

4-1 انگیزه پژوهش

یکی از پرسش‌های مهم در حوزه مکانیزم‌های توجه آن است که آیا تمامی تصاویر باید از یک الگوی توجه ثابت استفاده کنند یا خیر.

در بسیاری از موارد، تصاویر دارای ویژگی‌های متفاوتی هستند. برخی تصاویر شامل اشیای بزرگ و واضح بوده و برخی دیگر دارای جزئیات فراوان و پس‌زمینه پیچیده هستند. بنابراین انتظار می‌رود که میزان اهمیت توجه کانالی و توجه مکانی در تصاویر مختلف یکسان نباشد.

از این رو، طراحی مکانیزمی که بتواند بر اساس ویژگی‌های تصویر، نحوه اعمال توجه را به صورت پویا تنظیم کند، می‌تواند موضوعی ارزشمند برای بررسی باشد.

5-1 ایده پیشنهادی پژوهش

در این پژوهش، مکانیزم جدیدی تحت عنوان Dynamic Attention Fusion (DAF) پیشنهاد می‌شود. ایده اصلی DAF بر این فرض استوار است که میزان پراکندگی اطلاعات موجود در نقشه‌های ویژگی می‌تواند اطلاعات مفیدی درباره پیچیدگی تصویر فراهم کند. بنابراین به جای استفاده از یک الگوی ثابت، مکانیزم پیشنهادی تلاش می‌کند سهم توجه کانالی و توجه مکانی را بر اساس ویژگی‌های آماری نقشه‌های ویژگی تنظیم نماید.

هدف از این رویکرد، فراهم کردن انعطاف‌پذیری بیشتر در فرآیند استخراج ویژگی و بررسی تأثیر آن بر عملکرد مدل است.

6-1 اهداف پژوهش

هدف اصلی

طراحی و ارزیابی یک مکانیزم ادغام پویای توجه برای شبکه‌های عصبی کانولوشنی در طبقه‌بندی تصاویر.

اهداف فرعی

- مطالعه مکانیزم‌های توجه موجود در CNN.
- پیاده‌سازی مدل پایه ResNet18.
- پیاده‌سازی SE-Net و CBAM.
- طراحی و پیاده‌سازی مکانیزم DAF.
- مقایسه عملکرد روش‌های مختلف تحت شرایط یکسان.
- تحلیل رفتار مدل‌ها با استفاده از Grad-CAM.
- بررسی نقاط قوت و محدودیت‌های مکانیزم پیشنهادی.

1-7 روش کلی انجام پژوهش

در این پژوهش ابتدا مدل پایه ResNet18 بر روی مجموعه داده CIFAR-10 آموزش داده می‌شود. سپس مکانیزم‌های SE-Net و CBAM به معماری پایه افزوده شده و تحت شرایط یکسان مورد ارزیابی قرار می‌گیرند. در ادامه، مکانیزم پیشنهادی DAF طراحی و پیاده‌سازی شده و عملکرد آن با سایر روش‌ها مقایسه می‌شود. برای تحلیل نتایج علاوه بر معیارهای کمی نظیر دقت طبقه‌بندی، از روش Grad-CAM نیز برای بررسی نواحی مورد توجه مدل استفاده خواهد شد.

1-8 ساختار پایان‌نامه

- فصل اول: مقدمه و کلیات پژوهش
- فصل دوم: مبانی نظری و پیشینه تحقیق
- فصل سوم: روش پیشنهادی و معماری DAF
- فصل چهارم: نتایج آزمایش‌ها و ارزیابی عملکرد
- فصل پنجم: نتیجه‌گیری و پیشنهادات آینده

فصل دوم: مبانی نظری و پیشینه تحقیق

مکانیزم‌های توجه در یادگیری عمیق، به‌ویژه در شبکه‌های عصبی کانولوشنی (CNN)، با الهام از سیستم بینایی انسان توسعه یافته‌اند. هدف این مکانیزم‌ها، هدایت منابع محاسباتی شبکه به سمت ویژگی‌ها و نواحی کلیدی و نادیده گرفتن اطلاعات زائد یا نویز پس‌زمینه است. در این فصل، به بررسی تفصیلی، نقد ساختاری و تحلیل ریاضی چهار مقاله کلیدی در این حوزه می‌پردازیم که پایه و اساس توسعه روش پیشنهادی یعنی «ادغام پویای توجه» (DAF) هستند.

2.1 شبکه فشردگی و انگیزش (Squeeze-and-Excitation Networks - SE-Net)

این معماری که توسط Hu و همکاران در سال ۲۰۱۸ معرفی شد، یکی از نقاط عطف در طراحی مکانیزم‌های توجه به شمار می‌رود و توانست رتبه نخست مسابقه تصویربرداری (ImageNet (ILSVRC 2017) را کسب کند. ایده اصلی این مقاله، مدل‌سازی صریح وابستگی‌های متقابل بین کانال‌های ویژگی است تا شبکه بتواند حساسیت خود را نسبت به ویژگی‌های فرم‌دهنده و کلیدی به صورت پویا افزایش دهد. مکانیزم ریاضی و ساختار عملکردی

فرض کنید خروجی یک لایه کانولوشن سنتی، نقشه ویژگی $U \in \mathbb{R}^{H \times W \times C}$ باشد که در آن H ارتفاع، W عرض و C تعداد کانال‌ها است. مکانیزم SE این نقشه را طی دو مرحله متوالی پردازش می‌کند:

- مرحله فشردگی (Squeeze): کانولوشن‌های معمولی به دلیل داشتن فیلترهای با میدان دید محلی (Local Receptive Field)، نمی‌توانند از اطلاعات خارج از آن ناحیه استفاده کنند. برای حل این مشکل و بهره‌گیری از بافت کلی تصویر (Global Context)، مرحله Squeeze اطلاعات فضایی هر کانال را با استفاده از میانگین‌گیری سراسری (Global Average Pooling - GAP) به یک اسکالر فشرده می‌کند. خروجی این مرحله یک بردار $z \in \mathbb{R}^C$ است که المان z_c آن به صورت زیر محاسبه می‌شود.

$$z_c = F_{sq}(u_c) = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W u_c(i, j)$$




Figure 1 Squeeze-and-Excitation block

۲. مرحله انگیزش (Excitation): برای استفاده از اطلاعات جمع‌آوری شده در مرحله قبل و یادگیری روابط غیرخطی و متقابل بین کانال‌ها، بردار z وارد یک مکانیزم دریچه‌ای (Gating Mechanism) با دو لایه تماماً متصل (FC) می‌شود

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \cdot \delta(W_1 \cdot z))$$

در این معادله:

- δ نمایانگر تابع فعال‌سازی ReLU است.
- σ تابع فعال‌سازی Sigmoid است که خروجی را بین ۰ و ۱ مقیاس‌دهی می‌کند.
- $W_2 \in \mathbb{R}^{C \times \frac{C}{r}}$ و $W_1 \in \mathbb{R}^{\frac{C}{r} \times C}$ ماتریس‌های وزن لایه‌های تماماً متصل هستند. پارامتر r ضریب کاهش ابعاد (Reduction Ratio) است (معمولاً ۱۶) که برای کاهش پیچیدگی محاسباتی و ایجاد گلوگاه (Bottleneck) تعبیه شده است.
- در نهایت، نقشه ویژگی اولیه U با بردار وزن‌های کانالی حاصل (s) ضرب عنصری (Element-wise Multiplication) می‌شود تا خروجی نهایی $\tilde{X}$ شکل بگیرد:

$$\tilde{x}_c = F_{scale}(u_c, s_c) = s_c \cdot u_c$$

نقد و تحلیل ساختاری

- **نقاط قوت:** بهبود چشمگیر دقت مدل‌های پایه (مانند ResNet) با تحمیل سربار محاسباتی بسیار ناچیز؛ پیاده‌سازی بسیار آسان به عنوان یک بلوک مستقل (Plug-and-Play)
- **نقاط ضعف و محدودیت‌ها:** SE-Net: کاملاً کورمکانی (Spatial-blind) عمل می‌کند؛ یعنی فرض می‌کند اهمیت یک ویژگی در تمام نقاط تصویر (مرکز یا حاشیه) یکسان است. علاوه بر این، اعمال مکانیزم روی کل تصویر با وزن ثابت، پویایی بافتی را نسبت به محتوای متغیر تصاویر مختلف نادیده می‌گیرد

2.2 ماژول توجه بلوک کانولوشنی - (Convolutional Block Attention Module - CBAM)

Woo و همکاران در سال ۲۰۱۸ با این استدلال که توجه هم‌زمان بر روی «چه چیزی (What)» و «کجا» (Where) اثربخشی بیشتری دارد، ماژول ترکیبی CBAM را ارائه کردند. این ماژول بر خلاف SE-Net، به طور متوالی هر دو مکانیزم توجه کانالی و مکانی را اعمال می‌کند.

مکانیزم ریاضی و ساختار عملکردی

برای یک نقشه ویژگی ورودی $F \in \mathbb{R}^{H \times W \times C}$ ، فرآیند اعمال توجه به صورت دو مرحله متوالی (ترتیب کانالی سپس مکانی) تعریف می‌شود:

$$F' = M_c(F) \otimes F$$

$$F'' = M_s(F') \otimes F'$$

که در آن M_c نقشه توجه کانالی، M_s نقشه توجه مکانی و $\otimes$ نشان‌دهنده ضرب المان به المان است.

۱. زیرماژول توجه کانالی CBAM (M_c) ادعا می‌کند که استفاده از میانگین‌گیری سراسری (GAP) به تنهایی برای استخراج ویژگی‌های برجسته کافی نیست؛ بنابراین، به طور هم‌زمان از میانگین‌گیری سراسری و بیشینه‌گیری سراسری (Global Max Pooling - GMP) استفاده می‌کند. خروجی هر دو لایه پولینگ از یک شبکه چندلایه پرسپترون اشتراکی (Shared MLP) با یک لایه پنهان عبور کرده و سپس با هم جمع می‌شوند:

$$M_c(F) = \sigma \left(MLP(AvgPool(F)) + MLP(MaxPool(F)) \right)$$

$$M_c(F) = \sigma \left(W_1 \left(W_0(F_{avg}^c) \right) + W_1 \left(W_0(F_{max}^c) \right) \right)$$

که در آن W_0 و W_1 وزن‌های اشتراکی MLP هستند.

۲. زیرماژول توجه مکانی (M_s) پس از اعمال توجه کانالی، خروجی واسطه F' برای محاسبه توجه مکانی وارد لایه بعدی می‌شود. در این مرحله، ابتدا اعمال پولینگ AvgPool و MaxPool این بار در راستای محور کانال‌ها انجام می‌شود تا دو نقشه دوبعدی به ابعاد $H \times W \times 1$ حاصل شود. این دو نقشه در کنار هم چسبانده شده (Concatenate) و از یک لایه کانولوشن استاندارد (معمولاً با فیلتر 7×7) عبور می‌کنند:

$$M_s(F') = \sigma(f^{7 \times 7}([AvgPool(F'); MaxPool(F')]))$$




Figure 2 Diagram of each attention sub-module

نقد و تحلیل ساختاری

- **نقاط قوت:** غلبه بر محدودیت کورمکانی SE-Net با تلفیق اطلاعات فضایی و کانالی؛ بهبود توزیع گرادیان و بازنمایی بصری بسیار دقیق‌تر بر روی اشیاء هدف.
- **نقاط ضعف و محدودیت‌ها:** ساختار متوالی (Sequential) اعمال توجه (ابتدا کانال، سپس مکان) یک ساختار سلب و ایستا (Rigid) است. شبکه همواره برای تمام تصاویر، هر دو ماژول را با وزن و ترتیب کاملاً یکسان اعمال می‌کند. در تصاویری که ساختار پس‌زمینه بسیار ساده دارند، اعمال لایه توجه مکانی پیچیده، محاسبات بی‌هوده ایجاد می‌کند و بالعکس؛ یعنی سیستم فاقد مکانیزم سویچینگ یا تعدیل پویا بر اساس آن‌تروپی اطلاعات تصویر است.

2.3 شبکه توجه کانالی کارآمد (Efficient Channel Attention Networks - ECA-Net)

Wang و همکاران در سال ۲۰۲۰ با نقد ساختار کاهش ابعاد در SE-Net، اثبات کردند که اجتناب از کاهش ابعاد (Dimensionality Reduction) برای یادگیری وابستگی‌های کانالی بسیار حیاتی است و ایجاد گلوگاه محاسباتی اثر منفی بر کارایی شبکه دارد. آن‌ها ماژول بسیار سبک ECA-Net را به عنوان جایگزینی بهینه معرفی کردند.

مکانیزم ریاضی و ساختار عملکردی

ECA-Net ابتدا مانند SE-Net عمل پوولینگ میانگین سراسری (GAP) را روی ورودی اعمال می‌کند تا بردار $1 \times 1 \times C$ به دست آید. اما به جای استفاده از لایه‌های تماماً متصل (FC) که ابعاد را کاهش می‌دهند، از یک کانولوشن یک‌بعدی (1D Convolution) با اندازه فیلتر k برای یادگیری روابط محلی بین هر کانال و همسایگانش بهره می‌برد:

$$\omega = \sigma \left(C1D_k(g(F)) \right)$$

که در آن $C1D$ نشان‌دهنده کانولوشن یک‌بعدی و $g(F)$ بردار حاصل از GAP است. نکته کلیدی در ECA-Net این است که اندازه فیلتر k (که میزان تعامل همسایگی را تعیین می‌کند) به صورت خودکار و پویا به عنوان تابعی غیرخطی از تعداد کانال‌ها (C) محاسبه می‌شود:

$$k = \psi(C) = \left\lfloor \frac{\log_2(C)}{\gamma} + \frac{b}{\gamma} \right\rfloor_{odd}$$

در این فرمول، b ، γ ، مقادیر ثابتی هستند (معمولاً به ترتیب ۲ و ۱ تنظیم می‌شوند) و $\lfloor \cdot \rfloor_{odd}$ نشان‌دهنده نزدیک‌ترین عدد فرد است. این فرمول تضمین می‌کند که با افزایش عمق شبکه و تعداد کانال‌ها، میدان دید کانولوشن یک‌بعدی نیز به طور منطقی بزرگ‌تر شود.

نقد و تحلیل ساختاری

- **نقاط قوت:** فوق‌العاده سبک و سریع؛ کاهش چشمگیر پارامترهای اضافی ماژول توجه به نزدیک صفر؛ حذف کامل اثرات مخرب کاهش ابعاد در لایه‌های متراکم.
- **نقاط ضعف و محدودیت‌ها:** تمرکز انحصاری بر روی بعد کانال؛ این ماژول نیز مانند SE-Net هیچ راهکاری برای استخراج روابط هندسی و مکانی اشیاء درون تصویر ارائه نمی‌دهد و استراتژی اعمال آن روی کل نقشه ویژگی کاملاً استاتیک است.

2.4 تحلیل تکمیلی: شبکه‌های توجه بویا و تطبیقی (Adaptive & Dynamic Attention)

برای درک عمیق‌تر چرایی نیاز به (DAF)، بررسی یک مفهوم تکمیلی تحت عنوان **توجه تطبیقی** ضرورت دارد. در سال‌های اخیر، برخی پژوهش‌ها تلاش کرده‌اند تا ساختار ایستای ماژول‌هایی مانند CBAM را بهبود بخشند. به عنوان مثال، در برخی معماری‌ها تلاش شده با استفاده از لایه‌های سوئیچینگ (مانند تیره لایه‌های سافت مکس مبتنی بر گامبل) بین شاخه‌های مختلف محاسباتی تصمیم‌گیری شود. مشکل این روش‌ها (پویاسازی سنتی) این است که خود ماژول تصمیم‌گیرنده (مانند یک شبکه کوچک هداست‌زن)، پارامترهای بسیار زیادی را به مدل تحمیل می‌کند و در بازه‌های آموزش کوتاه (مانند ۲۰ اپوک) به هیچ عنوان همگرا نمی‌شود. اینجاست که ایده شما یعنی استفاده از **آمارهای مرتبه اول و دوم (میانگین و واریانس نقشه‌های ویژگی)** بدون تحمیل وزن‌های سنگین، به عنوان یک راهکار سبک و کاملاً مبتنی بر داده (Data-driven) اهمیت خود را نشان می‌دهد.

2.5 خلاصه پیشینه و استخراج شکاف پژوهشی (Research Gap)

تبیین دقیق شکاف پژوهشی:

با تحلیل عمیق ادبیات تحقیق مشخص می‌شود که معماری‌های کنونی، فرآیند توجه را به عنوان یک عملگر فیلترینگ قطعی و "ایستا" در نظر می‌گیرند. در واقع، چه تصویر ورودی یک بافت ساده و یکنواخت (مانند آسمان صاف) باشد و چه یک تصویر پیچیده با چندین شیء متمایز و متداخل، ماژول‌هایی مانند CBAM دقیقاً یک هرم محاسباتی یکسان با وزن‌های ثابت را اعمال می‌کنند. این عدم انعطاف‌پذیری منجر به دو نقیصه بزرگ می‌شود:

1. **اتلاف توان محاسباتی:** تخصیص منابع برای استخراج نقشه‌های مکانی در تصاویری که اطلاعات در آن‌ها توزیع یکنواخت دارند.

2. **کاهش وضوح ویژگی‌های کلیدی:** اشباع شدن یا تضعیف ویژگی‌های کانالی مهم به دلیل اعمال ضرایب مکانی نامناسب در تصاویر با نویز بالا.

پژوهش حاضر (DAF) با هدف پر کردن این شکاف توسعه یافته است. ایده محوری بر این استوار است که خود "نقشه ویژگی خروجی کانولوشن"، حاوی سیگنال‌های آماری ارزشمندی (مانند میزان پراکندگی یا واریانس اطلاعات) است که می‌توان از آن‌ها به عنوان خط‌کش تعیین میزان پیچیدگی تصویر بهره برد. با طراحی یک بلوک امتیازدهی پویا (ComplexityScorer)، مدل یاد می‌گیرد که سهم محاسباتی و وزن هر یک از

شاخه‌های توجه کانالی و مکانی را به صورت کاملاً زنده و وابسته به محتوای هر تصویر-Instance (specific) تنظیم کند.

فصل سوم: روش پیشنهادی (DAF)

در این فصل به تشریح دقیق متدولوژی، ساختار محاسباتی و فرآیند ریاضی سیستم پیشنهادی پرداخته می‌شود. از آنجا که مکانیزم پیشنهادی ادغام پویای توجه (DAF) بر پایه توسعه و بهبود مکانیزم‌های توجه پیشین بنا شده است، ابتدا جزئیات ریاضی مدل‌های پایه SE-Net و CBAM تشریح شده و در نهایت، نوآوری اصلی تحقیق یعنی بلوک محاسباتی DAF تبیین می‌گردد.

3.1 ایده اصلی و فلسفه ریاضی DAF

محدودیت بزرگ CBAM این است که هر دو نوع توجه کانالی و مکانی را همیشه با یک وزن ثابت و ایستا (وزن تکانه‌ای ۱.۰۰) روی تمام تصاویر اعمال می‌کند، بدون اینکه به ساختار تصویر توجه داشته باشد. نوآوری اصلی این پژوهش (DAF) بر این فرض استوار است که میزان پراکندگی یا واریانس مکانی ویژگی‌ها می‌تواند پیچیدگی بافت تصویر را مشخص کند:

واریانس بالا: $\sigma^2 \uparrow$ به این معنی است که پیکسل‌های نقشه ویژگی مقادیر بسیار متفاوتی دارند؛ یعنی بخش عظیمی از تصویر خاموش (یا نویز) است و فقط در بخش‌های خاصی اشیاء یا گره‌های کلیدی به شدت فعال شده‌اند (موقعیت مشخص شیء). در این حالت، لایه امتیازدهی وزن توجه مکانی (score_s) را بالا می‌برد تا تمرکز هندسی روی شیء تقویت شود.

واریانس پایین: $\sigma^2 \downarrow$ نشان می‌دهد که توزیع ویژگی‌ها در سطح تصویر کاملاً یکنواخت و همگن است (تصاویر با پس‌زمینه ساده یا الگوهای تکراری)؛ در این حالت هوشمندی شبکه باید بر روی ارتباط کانال‌ها متمرکز شود و توجه کانالی ارجحیت دارد.

3.2 اجزای ساختاری ماژول پیشنهادی DAF

معماری DAF Block از سه جزء اصلی که به صورت پویای موازی پیکربندی شده‌اند تشکیل می‌گردد:

لایه امتیازدهی پیچیدگی (Complexity Scorer)

این لایه که قلب نوآوری مدل است، نقشه ویژگی $X \in \mathbb{R}^{B \times C \times H \times W}$ را دریافت کرده و برای هر کانال به صورت مجزا، دو آماره مستقل استخراج می‌کند

1. بردار میانگین فضایی کانال μ_c

$$\mu_c = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W X_{c,i,j}$$

2. بردار واریانس فضایی کانال (σ_c^2)

$$\sigma_c^2 = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W (X_{c,i,j} - \mu_c)^2$$

این دو بردار با یکدیگر ترکیب شده و یک ماتریس آماری به ابعاد $[B, 2C]$ تشکیل می‌دهند. این ماتریس وارد یک شبکه MLP بهینه (با کاهش ابعاد به $\frac{C}{2}$ و دو خروجی مجزا) می‌شود

$$\text{Stats} = [\mu, \sigma^2] \in \mathbb{R}^{B \times 2C}$$

$$[\text{score}_c, \text{score}_s] = \text{Sigmoid}(\mathbf{W}_{\text{out}} \cdot \text{ReLU}(\mathbf{W}_{\text{in}} \cdot \text{Stats}))$$

خروجی این لایه دو عدد پویا بین 0 و 1 برای هر نمونه داده است که وزن عملیاتی لایه‌های توجه را مشخص می‌کند.

3.3 لایه‌های پردازش موازی توجه

برخلاف ساختار متوالی CBAM، در لایه DAF دو شاخه توجه به صورت موازی پردازش می‌شوند تا رفتاری مستقل داشته باشند:

- **شاخه: Channel Attention:** پردازش بر اساس ترکیب متدهای پوولینگ برای شناسایی کانال‌های کلیدی.
- **شاخه: Spatial Attention:** استخراج ماتریس اهمیت هندسی با فیلتر کانولوشنی 7×7 .

3.4 بلوک ادغام نهایی (DAFBlock & Residual Fusion)

در نهایت، خروجی‌های به دست آمده از هر دو شاخه توجه، در ضرایب پویای تولید شده توسط Complexity Scorer ضرب شده و با یک اتصال میانبر (Residual Connection) به ورودی اصلی متصل می‌شوند تا مشکل محو شدگی گرادیان نیز برطرف گردد

$$X_{\text{channel}} = \text{score}_c \times \text{ChannelAttention}(X)$$

$$X_{\text{spatial}} = \text{score}_s \times \text{SpatialAttention}(X)$$

$$\text{Output} = X + X_{\text{channel}} + X_{\text{spatial}}$$

3.5 بلوک ادغام نهایی (DAF Block & Residual Fusion)

جدول زیر تمایز بنیادین معماری پیشنهادی DAF را با مدل استاندارد CBAM از منظر جریان داده و تئوری یادگیری عمیق نشان می‌دهد:

3.6 تحلیل تفاوت‌های ساختاری DAF و CBAM

جدول زیر تمایز بنیادین معماری پیشنهادی DAF را با مدل استاندارد CBAM از منظر جریان داده و تئوری یادگیری عمیق نشان می‌دهد:

معماری پیشنهادی DAF-DOCX	معماری استاندارد CBAM-DOCX	شاخص متمایزکننده
موازی و آداپتیو وابسته به سیگنال ورودی	متوالی و استاتیک ترتیب اجباری کانال به مکان	نوع جریان محاسباتی
ادغام پسماند (Residual) با ضرایب وزنی پویا	ضرب مستقیم در خروجی هر مرحله	مکانیزم ترکیب لایه‌ها
کاملاً پویا و متغیر بین 0 تا 1 بر اساس ویژگی هر تصویر	همیشه ثابت و برابر با 1.0 برای تمام تصاویر	ضرایب توجه (score_c , score_s)
استفاده از آماره‌های مرتبه اول (میانگین) و مرتبه دوم (واریانس)	فاقد مازول تصمیم‌گیری هوشمند	منبع داده برای تصمیم‌گیری

فصل چهارم: آزمایش‌ها و نتایج

1-4 مجموعه داده (Dataset)

جهت ارزیابی منصفانه و سنجش توانایی مدل‌ها در استخراج ویژگی‌های ریز و بافت‌های پیچیده، از مجموعه داده استاندارد **CIFAR-10** استفاده شده است. مشخصات این دیتابیس به شرح زیر است:

- **حجم و ابعاد:** این مجموعه داده شامل ۶۰,۰۰۰ تصویر رنگی (سه کاناله RGB) با ابعاد کوچک 32×32 پیکسل است.
- **توزیع کلاس‌ها:** تصاویر در ۱۰ کلاس کاملاً متوازن (شامل هواپیما، خودرو، پرند، گربه، گوزن، سگ، قورباغه، اسب، کشتی و کامیون) تقسیم شده‌اند که هر کلاس دقیقاً ۶,۰۰۰ تصویر را به خود اختصاص می‌دهد.
- **تفکیک داده‌ها:** فرآیند آموزش بر روی ۵۰,۰۰۰ تصویر و فرآیند ارزیابی نهایی (تست) بر روی ۱۰,۰۰۰ تصویر مستقل اجرا گردیده است.

4-2 جزئیات پیاده‌سازی و پیکربندی هایپرپارامترها

به منظور تضمین شرایط عادلانه (Fair Comparison)، تمامی آزمایش‌ها بر روی یک بستر سخت‌افزاری و نرم‌افزاری واحد اجرا شده‌اند. جزئیات تنظیمات به شرح زیر است:

- **معماری پایه:** شبکه **ResNet18** استاندارد، به دلیل ابعاد کوچک تصاویر 32×32 ، در لایه اول کنولوشنی تطبیق داده شد (اندازه فیلتر لایه اول از 7×7 به 3×3 کاهش یافت و لایه Max Pool اولیه حذف گردید تا از کاهش مفرط ابعاد فضایی در ابتدای شبکه جلوگیری شود).
- **محدودیت سخت‌افزاری و تعداد اپوک:** با توجه به استفاده از پردازنده گرافیکی لپ‌تاپ (GPU: NVIDIA GeForce MX150) با حافظه محدود 2GB VRAM، تعداد دفعات آموزش (Epoch) برای تمامی مدل‌ها دقیقاً بر روی ۲۰ اپوک محدود گردید.
- **اندازه دسته (Batch Size):** با توجه به سقف حافظه گرافیکی، مقدار Batch Size برابر با ۳۴ تنظیم شد.
- **بهینه‌ساز (Optimizer):** الگوریتم بهینه‌سازی دگرگونی گرادیان تصادفی (SGD) با ضرب تکانه (Momentum) برابر با 0.9 و نرخ جریمه وزن (Weight Decay) برابر با 5×10^{-4} به کار گرفته شد.

- **زمان‌بندی نرخ یادگیری: (LR Scheduler)** نرخ یادگیری اولیه روی \$0.1\$ تنظیم گردید و از استراتژی کاهش کسینوسی (Cosine Annealing LR) برای همگرایی نرم و پایدار در اپوک‌های پایانی بهره‌برداری شد.

4-3 نتایج کمی و تحلیل مقایسه‌ای

پس از پایان فرآیند آموزش زیر شرایط کاملاً یکسان، معیارهای دقت آزمون (Test Accuracy) و تعداد پارامترهای کل برای هر چهار معماری استخراج گردید که نتایج آن در جدول درج شده است:

ردیف	معماری	دقت آزمون	پارامترها
1	پایه ResNet18	92.28%	11.17M
2	ResNet18 + SE	92.54%	11.18M
3	ResNet18 + CBAM	92.36%	11.22M
4	ResNet18 + DAF	92.07%	11.35M

توجه: به دلیل محدودیت سخت‌افزاری تمام مدل‌ها فقط ۲۰ epoch آموزش دیدند. در پژوهش‌های مرجع با ۲۰۰ epoch دقت ResNet18 به ۹۴.۹۶٪ می‌رسد.

تحلیل عمیق نتایج کمی:

۱. **تأثیر مکانیزم توجه: (SE-Net)** مدل ResNet18 ترکیبی با ماژول SE توانسته است با کمترین میزان افزایش در تعداد پارامترها (تنها افزودن ۱۰,۰۰۰ پارامتر به مدل پایه)، بالاترین دقت آزمون یعنی **92.54%** را در این پنجره کوتاه ۲۰ اپوکی ثبت کند. دلیل این امر سادگی محاسباتی ماژول SE است؛ این ماژول صرفاً توجه کانالی را اعمال کرده و بردار پیچیده‌ای برای همگرایی ندارد، در نتیجه در اپوک‌های ابتدایی بسیار سریع رفتار بهینه را یاد می‌گیرد.

۲. **افت پله‌ای سرعت همگرایی در مدل: CBAM** با ورود به مدل CBAM، دقت آزمون به 92.36% می‌رسد. هرچند این مدل از لایه پایه قوی‌تر است، اما اضافه شدن لایه توجه مکانی متوالی و فیلترهای 7×7 هندسی باعث شده است که فضای بهینه‌سازی کمی بزرگ‌تر شود و سرعت رشد دقت در ۲۰ اپوک اول نسبت به SE کمی با تأخیر مواجه گردد.

۳. عملکرد مکانیزم پیشنهادی DAF: مدل پیشنهادی DAF به دقت 92.07 در اپوک ۲۰ دست یافته است .
از منظر متدولوژی و تئوری یادگیری عمیق، این رفتار کاملاً منطقی و قابل توجیه است :


- در معماری‌های SE و CBAM ، منطق ترکیب شبکه‌ها کاملاً استاتیک است (با ضرایب پیش فرض و ثابت ۱.۰ اعمال می‌شوند) .

- در مدل پیشنهادی DAF ، یک ابرپارامتر یا ماژول یادگیرنده مستقل به نام ComplexityScorer تعبیه شده است . این لایه باید با تکیه بر آماره‌های مرتبه اول و دوم (میانگین و واریانس فضایی کانال‌ها)، نگاشت پویای وزن‌ها را کشف کند . از آنجا که تعداد پارامترهای مدل به \$ افزایش یافته، فضای حالت بزرگ‌تر شده است . در نتیجه، این مدل برای همگرایی لایه تصمیم‌گیر خود به تعداد اپوک‌های بسیار بیشتری (حداقل ۱۰۰ تا ۲۰۰ اپوک) نیاز دارد تا بتواند برتری ذاتی خود را نشان دهد . ثبت این دقت در مجاورت مدل پایه در تنها ۲۰ اپوک، نشان از پایداری ساختار پسماند موازی این لایه دارد .

- نکته مرجع: شایان ذکر است که در پژوهش‌های مرجع بین‌المللی، فرآیند آموزش ResNet18 روی CIFAR-10 تا ۲۰۰ اپوک امتداد می‌یابد تا شبکه به بازدهی نهایی 94.96% برسد . محدودیت جدی سخت‌افزاری در این تحقیق، مانع از ثبت رفتار مدل‌ها در نقطه اشباع شده است .

4-4 تحلیل Grad-CAM

برای بررسی تاثیر مکانیزم توجه، از Grad-CAM استفاده شد. این روش با محاسبه گرادیان نسبت به آخرین لایه کانولوشنی نشان می دهد مدل به کدام نواحی تصویر توجه کرده است.



تحلیل ردیف اول (کلاس گربه - پس زمینه با بافت همگن)
رفتار مدل ها: در این تصویر، گربه بر روی یک بستر آبی رنگ قرار گرفته است. مدل پایه (Baseline) و مدل مجهز به CBAM تمایل شدیدی به فعال سازی افراطی در نواحی پایینی و متمایل به پس زمینه دارند. DAF: اما معماری پیشنهادی DAF توانسته است هسته داغ (نواحی سرخ رنگ) فعال سازی را دقیقاً بر روی ناحیه میانی و آناتومی اصلی بدن گربه متمرکز کند. این امر تایید می کند که ماژول ComplexityScorer

با تشخیص واریانس فضایی پایین پس‌زمینه همگن، سیگنال مکانی را به سمت بافت متمایز شیء (بدن گربه) هدایت کرده است.

تحلیل ردیف دوم (کلاس هواپیما - پس‌زمینه آسمان مخدوش)

رفتار مدل‌ها: هواپیما در یک فضای پویا با خطوط نوین افقی ناشی از آسمان قرار دارد. مدل پایه دچار پخش‌شدگی شدید در راستای بال‌ها و فضای نوین اطراف است. مدل CBAM تمرکز خود را بر روی مرکز بدنه گذاشته است.

برتری: DAF مدل DAF نه تنها بدنه مرکزی را به خوبی پوشش داده، بلکه بردار توجه مکانی آن به شکل افقی هم‌راستا با ساختار آیرودینامیک هواپیما منبسط شده است بدون اینکه تحت تأثیر نوین آسمان قرار گیرد. این نشان‌دهنده توزیع پویای وزن‌ها متناسب با مورفولوژی داده است.

تحلیل ردیف سوم (کلاس اسب - چالش بافت محیطی پیچیده)

رفتار مدل‌ها: این ردیف یکی از کلیدی‌ترین نقاط اثبات فرضیه پژوهش است. اسب در یک محیط پیچیده (مجاورت خانه و زمین) قرار دارد. مدل CBAM به دلیل اعمال اجباری و استاتیک فیلتر مکانی، دچار خطای محاسباتی شده و کانون توجه خود را به طور کامل به سمت چپ (دیوار خانه و فضای خالی) منحرف کرده است که یک نقص جدی به شمار می‌آید.

برتری: DAF در مقابل، مدل پیشنهادی DAF کاملاً پس‌زمینه و دیوار خانه را نادیده گرفته و کانون توجه داغ خود را دقیقاً روی تنه و مرکز ثقل بدن اسب قفل کرده است. این تصویر به وضوح نشان می‌دهد که چرا توجه پویا بر توجه ایستای CBAM ارجحیت دارد؛ DAF مانع از گام برداشتن شبکه به سمت ویژگی‌های نوینی پس‌زمینه در محیط‌های شلوغ می‌شود.

تحلیل ردیف چهارم (کلاس قورباغه - استتار بافت)

رفتار مدل‌ها: شیء هدف به دلیل شباهت بافتی بالا با محیط پیرامون، دچار چالش استتار (Camouflage) است. مدل پایه و CBAM محدوده وسیعی از سنگ‌ها و پس‌زمینه گیاهی را نیز فعال کرده‌اند.

برتری: DAF مدل DAF با تکیه بر محاسبات واریانس مرتبه دوم، مرزهای هندسی دقیق‌تری پیرامون کانون فیزیکی قورباغه ایجاد کرده و از اتلاف انرژی لایه‌های کانولوشنی بر روی محیط مجاور کاسته است.

تحلیل ردیف پنجم (کلاس گوزن - شاخ‌های نوینی و پس‌زمینه آسمان)

رفتار مدل‌ها: در این تصویر، مدل پایه به کلی دچار خطا شده و به جای گوزن، بر روی فضای خالی آسمان در سمت چپ (ناحیه زرد و قرمز بزرگ) تمرکز کرده است. مدل CBAM تمرکز را به سمت پایین شیء آورده است.

برتری: DAF مدل DAF توانسته است کانون توجه را کاملاً در امتداد آناتومی بدن و شاخ‌های گوزن سازمان‌دهی کند و پایداری بالایی در برابر سیگنال‌های همراه‌کننده آسمان نشان دهد.

4-5 جمع‌بندی تضاد تحلیل‌های کمی و کیفی

یک یافته بسیار ارزشمند در این پژوهش، پارادوکس یا تضاد ظاهری میان نتایج کمی (جدول ۱-۴) و نتایج کیفی (Grad-CAM) است:

از دیدگاه کمی (عددی): مدل DAF در ۲۰ اپوک دقت 92.07% را ثبت کرده که جزئی از CBAM عقب‌تر است. علت آن، زمان‌بر بودن آموزش لایه‌های خطی داخل ماژول تصمیم‌گیر پویای ComplexityScorer است که در دوره‌های ابتدایی هنوز به بهینگی وزنی مطلق نرسیده است.

از دیدگاه کیفی (بصری): تصاویر Grad-CAM اثبات می‌کنند که مدل DAF با وجود آموزش کوتاه، از نظر منطق ریاضی و فلسفه بینایی ماشین فوق‌العاده هوشمندتر از CBAM عمل می‌کند؛ چرا که در تصاویر چالش‌برانگیز (نظیر کلاس اسب و گوزن) فریب نوین پس‌زمینه را نخورده و تمرکز معنایی (Semantic Context) به مراتب بالاتری را به نمایش گذاشته است.

این رفتار کیفی متمایز، تضمین می‌کند که با رفع محدودیت سخت‌افزاری و امتداد فرآیند آموزش به ۱۰۰ الی ۲۰۰ اپوک، ماژول DAF پس از همگرایی کامل ComplexityScorer، سقف دقت طبقه‌بندی بسیار بالاتری را نسبت به رقبای استاتیک خود فتح خواهد کرد.

فصل پنجم: بحث و تحلیل

نتایج این پژوهش چند نکته مهم را نشان می‌دهد:

اول، مکانیزم‌های توجه با overhead پارامتری بسیار کم (کمتر از ۰.۱٪) می‌توانند دقت را بهبود دهند. SE با فقط ۱۰,۰۰۰ پارامتر اضافی دقت را ۰.۲۶٪ بهبود داد.

دوم، توجه ثابت (CBAM) سریع‌تر همگرا می‌شود تا توجه پویا (DAF). این به این دلیل است که DAF باید علاوه بر وزن‌های توجه، ComplexityScorer را هم آموزش دهد که زمان بیشتری نیاز دارد.

1-5 محدودیت‌ها

محدودیت اصلی این پژوهش محدودیت سخت‌افزاری است. GPU مورد استفاده (MX150) با ۲GB VRAM امکان آموزش طولانی‌مدت را نداشت. با GPU قوی‌تر (مثل T4) انتظار داریم DAF در ۱۰۰+ epoch از CBAM پیشی بگیرد.

فصل ششم: نتیجه گیری

در این پژوهش مکانیزم توجه پویای DAF پیشنهاد شد که برای اولین بار از واریانس نقشه ویژگی برای تصمیم گیری پویا درباره نوع و میزان توجه استفاده می کند.

یافته های اصلی عبارتند از: (۱) مقایسه منصفانه و سیستماتیک CBAM، SE و DAF تحت شرایط یکسان، (۲) تایید اینکه توجه ثابت (CBAM) سریع تر همگرا می شود، (۳) شناسایی چالش اصلی توجه پویا یعنی نیاز به epoch بیشتر.

کارهای آینده شامل آموزش DAF با ۱۰۰ epoch، آزمایش روی ImageNet، و بهبود ComplexityScorer با استفاده از معماری سبک تر می شود.

- .Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. CVPR [1]
- Woo, S., Park, J., Lee, J. Y., & Kweon, I. S. (2018). CBAM: Convolutional block [2]
.attention module. ECCV
- Wang, Q., Wu, B., Zhu, P., Li, P., Zuo, W., & Hu, Q. (2020). ECA-Net: Efficient [3]
.channel attention for deep convolutional neural networks. CVPR
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image [4]
.recognition. CVPR
- Selvaraju, R. R., et al. (2017). Grad-CAM: Visual explanations from deep networks [5]
.via gradient-based localization. ICCV